

SVEUČILIŠTE U OSIJEKU
Fakultet primijenjene matematike i informatike

SequenceAlignment

Razvoj programskog alata za poravnanje
i analizu bioloških sekvenci

Needleman–Wunsch i Smith–Waterman

Tehnička dokumentacija

Student: Antun Abičić

Mentor: doc. dr. sc. Luka Borožan

Datum: 8. rujna 2026.

Sadržaj

1	Uvod	2
1.1	O projektu	2
1.2	Ciljevi	2
2	Arhitektura programskog alata	3
2.1	Tehnologije	3
2.2	Struktura projekta	3
2.3	Opis modula	3
2.4	Tok podataka	4
3	Korisničko sučelje	5
3.1	Glavni zaslon	5
3.2	Medicinski primjeri	6
3.3	Dohvat sekvenci iz baze UniProt	6
3.4	Učitavanje FASTA datoteke	8
4	Vizualizacija rezultata	8
4.1	Matrica dinamičkog programiranja	8
4.2	Heatmap prikaz za velike matrice	9
4.3	Prikaz poravnanja i statistike	10
4.4	Detekcija mutacija	11
5	Implementacijski detalji	12
5.1	Needleman–Wunsch	12
5.2	Smith–Waterman	12
5.3	Animacija popunjavanja matrice	13
5.4	Prilagodljiva veličina ćelije	13
6	Instalacija i pokretanje	13
6.1	Preduvjeti	13
6.2	Postupak	14
	Literatura	15

1 Uvod

1.1 O projektu

Sequence Alignment je programski alat namijenjen vizualizaciji i usporedbi dvaju temeljnih algoritama za poravnanje bioloških sekvenci: **Needleman–Wunsch** (globalno poravnanje) i **Smith–Waterman** (lokalno poravnanje). Alat korisniku omogućuje unos DNA ili proteinskih sekvenci, podešavanje parametara bodovanja te promatranje kako algoritam korak po korak popunjava matricu dinamičkog programiranja i pronalazi optimalno poravnanje.

1.2 Ciljevi

1. Implementirati algoritme Needleman–Wunsch i Smith–Waterman temeljene na dinamičkom programiranju.
2. Vizualizirati matricu dinamičkog programiranja i traceback put.
3. Omogućiti usporedbu globalnog i lokalnog poravnanja na istim podacima.
4. Integrirati dohvat stvarnih sekvenci iz baze UniProt.
5. Demonstrirati praktičnu primjenu kroz detekciju mutacija.

2 Arhitektura programskog alata

2.1 Tehnologije

Sloj	Tehnologija	Uloga
Sučelje	React 18	komponente i upravljanje stanjem
Stiliziranje	inline CSS-in-JS	bez vanjskih ovisnosti
Algoritmi	JavaScript (ES6+)	izvođenje u pregledniku
Tipografija	Google Fonts	IBM Plex Mono, Orbitron
Vanjski podaci	UniProt REST API	dohvat proteinskih sekvenci
Alat za izgradnju	Create React App	razvojni poslužitelj i build

Alat je u trenutnoj verziji **potpuno klijentska** — algoritmi se izvode u pregledniku korisnika, bez poslužiteljskog dijela. Time je odziv trenutačan, a alat se može posluživati kao statični sadržaj.

2.2 Struktura projekta

```

1 sequence-alignment/
2 |-- public/
3 |   |-- index.html           # HTML predlozak
4 |-- src/
5 |   |-- index.js             # ulazna točka aplikacije
6 |   |-- index.css            # globalni stilovi
7 |   |-- App.js               # glavna komponenta, stanje i logika
8 |   |-- algorithms.js        # NW, SW, statistika, ciscenje ulaza
9 |   |-- constants.js         # paleta boja i stilski objekti
10 |   |-- data.js              # medicinski primjeri, UniProt, FASTA
11 |   |-- components/
12 |     |-- Header.jsx         # zaglavlje aplikacije
13 |     |-- Matrix.jsx         # matrica dinamičkog programiranja
14 |     |-- AlignmentResult.jsx # prikaz poravnanja i statistike
15 |     |-- MutationPanel.jsx  # panel detektiranih mutacija
16 |     |-- UniProtPanel.jsx   # pretraga i dohvat sekvenci
17 |     |-- FastaUpload.jsx    # učitavanje .fasta datoteka
18 |-- package.json
19 |-- README.md

```

Programski kôd 1: Struktura direktorija

2.3 Opis modula

Datoteka	Odgovornost
App.js	Drži cjelokupno stanje alata (sekvence, odabrani algoritam, parametri bodovanja, rezultati) i orkestrira animaciju popunjavanja matrice.
algorithms.js	Čiste funkcije bez nuspojava: <code>needlemanWunsch()</code> , <code>smithWaterman()</code> , <code>calcStats()</code> i <code>clean()</code> . Svaka vraća matricu, poravnate nizove i rezultat.
constants.js	Središnje mjesto za paletu boja (C) i stilske objekte (s). Promjena teme svodi se na izmjenu ove datoteke.

Datoteka	Odgovornost
<code>data.js</code>	Medicinski primjeri s opisom gena i mutacije, lokalna kopija UniProt zapisa, parser FASTA formata i funkcija za detekciju mutacija.
<code>Matrix.jsx</code>	Is crtava matricu s dinamičkom veličinom ćelije; za velike matrice prelazi u heatmap prikaz.
<code>AlignmentResult.jsx</code>	Prikazuje poravnate sekvence obojene po tipu pozicije te sažetu statistiku.
<code>MutationPanel.jsx</code>	Aktivira se samo za medicinske primjere; navodi poziciju, tip supstitucije i klinički kontekst.
<code>UniProtPanel.jsx</code>	Pretraga po nazivu ili identifikatoru, odabir raspona amino-kiselina dvostrukim kliznikom.
<code>FastaUpload.jsx</code>	Učitavanje lokalne <code>.fasta</code> datoteke i ekstrakcija sekvence.

2.4 Tok podataka

1. Korisnik unosi sekvence ručno, odabirom primjera, dohvatom iz UniProta ili učitavanjem FASTA datoteke.
2. Pritiskom na *Pokreni* funkcija `run()` normalizira ulaz i poziva odabrani algoritam iz `algorithms.js`.
3. Algoritam vraća objekt s matricom, poravnatim nizovima i rezultatom.
4. Brojač `revealCount` postupno se povećava, čime React ponovno is crtava matricu s većim brojem otkrivenih ćelija.
5. Po završetku animacije prikazuje se poravnanje, statistika te — ako je aktivan medicinski primjer — panel s mutacijama.

3 Korisničko sučelje

3.1 Glavni zaslon

Cjelokupan unos organiziran je u jednu karticu podijeljenu u logičke cjeline: primjeri, unos sekvenci, dohvat podataka, odabir algoritma i parametri bodovanja.

Slika 1: Glavni zaslon alata. Odozgo prema dolje: prečaci za DNA i proteinski primjer u gornjem desnom kutu; tri medicinska primjera za detekciju mutacija; polja za unos dviju sekvenci; ispod svakog polja panel za pretragu baze UniProt s kliznikom za odabir raspona i gumb za učitavanje FASTA datoteke; odabir algoritma; tri brojčanika za parametre bodovanja; prekidač za usporedni mod i gumb *Pokreni*.

Parametri bodovanja

Tri brojčanika izravno utječu na ponašanje algoritma:

- **Match** — nagrada za podudarni par. Veća vrijednost potiče algoritam da agresivnije traži podudaranja.
- **Mismatch** — kazna za nepodudarni par. Stroža kazna smanjuje toleranciju na razlike.
- **Gap** — kazna za umetanje praznine. Stroža kazna gura algoritam prema rješenjima s više nepodudaranja, a manje praznina; blaža kazna daje suprotan učinak.

Mogućnost interaktivne izmjene ovih vrijednosti pokazuje da optimalno poravnanje nije apsolutna kategorija, nego ovisi o odabranom modelu bodovanja.

3.2 Medicinski primjeri

Slika 2: Učitani medicinski primjer TP53. Odabirom primjera oznake polja mijenjaju se u *referentni genom* i *sekvenca pacijenta*, čime se naglašava klinički kontekst usporedbe. Aktivni primjer istaknut je narančastom bojom. Na slici je uključen i usporedni mod, pa su obje kartice algoritama označene kao aktivne.

Ugrađena su tri primjera:

Gen	Mutacija	Klinički značaj
TP53	G→A	Deaktivacija proteina p53, “čuvara genoma”; povezano s karcinomom dojke, pluća i debelog crijeva.
BRCA1	G→T	Smanjena sposobnost popravka DNA; znatno povišen rizik od nasljednog raka dojke i jajnika.
KRAS	G→C	Trajna aktivacija signala za diobu stanice; karcinom gušterače i pluća.

3.3 Dohvat sekvenci iz baze UniProt

UniProt je najveća javno dostupna baza proteinskih sekvenci, s više od 250 milijuna zapisa. Održavaju je EMBL-EBI, SIB i PIR, a pristup je besplatan i ne zahtijeva registraciju ni pristupni ključ.

SEKVENCA 1

ATGCAT

UNIPROT - pretraga po imenu ili ID-u

TP53 ↓ Traži

Raspon (od-do)

1 učitaj protein

TP53TG5	TP53-target gene 5 protein	290 aa
TP53BP1	TP53-binding protein 1	1972 aa
TP53	Cellular tumor antigen p53	393 aa
TIGAR	Fructose-2,6-bisphosphatase TIGAR	270 aa
RRM2B	Ribonucleoside-diphosphate reductase subunit	351 aa
TP53TG3	TP53-target gene 3 protein	124 aa
TRIAP1	TP53-regulated inhibitor of apoptosis 1	76 aa
MDM2	E3 ubiquitin-protein ligase Mdm2	491 aa

TP53 BRCA1 insulin hemoglobin EGFR

Upload .fasta datoteke za sekvencu 1

Slika 3: Pretraga po nazivu gena. Upisom pojma TP53 alat vraća listu pogodaka s identifikatorom, punim nazivom proteina i duljinom u aminokiselinama. Korisnik odabirom retka učitava sekvencu u polje za unos. Ispod liste nalaze se prečaci za često korištene proteine.

SEKVENCA 1

PPVAPAPAAPTPAAPAPAPSWPLSSSVPSQKTYQGSYGFRGLGFLHSGTAK

UNIPROT - pretraga po imenu ili ID-u

P04637 ↓ Traži

Raspon (od-do) aa 71-235 • 165 aa

1 393 aa (cijeli protein)

TP53 BRCA1 insulin hemoglobin EGFR

✓ TP53 • Cellular tumor antigen p53 – aa 71-235 (165 od 393)

Upload .fasta datoteke za sekvencu 1


Slika 4: Odabir raspona aminokiselina dvostrukim kliznikom. Budući da cjeloviti proteini često imaju više stotina aminokiselina, a matrica raste kvadratno, korisnik bira podsegment — ovdje aminokiseline 71–235 od ukupno 393 zapisa TP53. Odabrani raspon ispisan je iznad kliznika, a ispod njega prikazana je ukupna duljina proteina.

3.4 Učitavanje FASTA datoteke

FASTA je standardni tekstualni format za zapis bioloških sekvenci. Prvi redak počinje znakom > i sadrži identifikator i opis, a svi sljedeći retci sadrže samu sekvencu.

```
1 >sp|P04637|P53_HUMAN Cellular tumor antigen p53 OS=Homo sapiens
2 MEEPQSDPSVEPPLSQETFSDLWKLLPENNVLSPLPSQAMDDLMLSPDDIEQWFTEDPGP
3 DEAPRMPEAAPPVAPAPAAPTPAAPAPAPSWPLSSSVPSQKTYQGSYGFRLLGFLHSGTAK
```

Programski kôd 2: Primjer FASTA zapisa




Slika 5: Slika prikazuje učitavanje .fasta datoteke.

4 Vizualizacija rezultata


4.1 Matrica dinamičkog programiranja

Matrica je središnji element vizualizacije. Popunjava se animirano, a bojama se kodira značenje vrijednosti:

Boja ćelije	Značenje
Zelena	ćelija pripada optimalnom traceback putu
Plava	pozitivna vrijednost — dobro poravnanje do te točke
Crvena	negativna vrijednost — loše poravnanje do te točke
Neutralna	vrijednost nula




Slika 6: Needleman–Wunsch nad sekvencama ATGCAT i ATGTCAT. Uočljiva je inicijalizacija: prvi redak i stupac padaju u koracima od -2 , što odgovara kazni za prazninu. Zeleni traceback put teče dijagonalno od gornjeg lijevog do donjeg desnog kuta, uz jedno skretanje koje odgovara umetnutoj praznini. Konačni rezultat 10 nalazi se u donjem desnom kutu.




Slika 7: Smith–Waterman nad istim sekvencama. Za razliku od prethodne matrice, prvi redak i stupac ostaju na nuli, a nijedna ćelija nije negativna — posljedica pravila da vrijednost ne pada ispod nule. Traceback počinje u ćeliji s vrijednošću 10 i prekida se čim naide na nulu, pa je istaknuti put kraći nego kod globalnog poravnanja.

4.2 Heatmap prikaz za velike matrice

Za sekvence dulje od nekoliko desetaka znakova brojčani prikaz postaje nečitljiv. Alat tada prelazi na heatmap: svaka ćelija postaje obojeni piksel čiji intenzitet odgovara vrijednosti, a traceback put ostaje istaknut zelenom bojom.



Slika 8: Heatmap Needleman–Wunsch matrice dimenzija 80×80 . Gradijent od crvene prema plavoj prati rast vrijednosti, a zelena isprekidana dijagonala predstavlja traceback put. Ispod matrice nalazi se poravnanje prelomljeno u blokove sa oznakama pozicija; sličnost je 16,7%, što odgovara usporedbi dvaju nesrodnih proteina.




Slika 9: Heatmap Smith–Waterman matrice nad istim parom sekvenci. Pozadina je pretežno jednolična jer većina ćelija ima vrijednost nula. Algoritam je izdvojio kratak segment **QKT** na pozicijama 30–32 prve i 4–6 druge sekvence, sa 100% podudarnošću — ilustracija ključne razlike: lokalno poravnanje pronalazi najbolji podsegment i zanemaruje ostatak.

4.3 Prikaz poravnanja i statistike

Poravnate sekvence prikazuju se jedna ispod druge, sa okomitim crticama između podudarnih parova. Svaki je znak obojen prema tipu pozicije: zeleno za podudaranje, crveno za nepodudaranje, sivo za prazninu. Ispod poravnanja nalazi se sažetak s brojem podudaranja, nepodudaranja i praznina te postotak sličnosti prikazan i brojčano i trakom.

4.4 Detekcija mutacija



Slika 10: Rezultat za medicinski primjer TP53. Poravnanje pokazuje 94,7% sličnosti uz jedno nepodudaranje. Ispod poravnanja aktivira se panel *Mutacija detektirana* koji navodi poziciju 10, bazu u referentnom genomu (G), bazu u sekvenci pacijenta (A), tip promjene (supstitucija G → A) te kratko objašnjenje kliničkog značaja mutacije gena TP53.

Panel se popunjava iz funkcije `detectMutations()`, koja prolazi poravnatim nizovima i bilježi svaku poziciju na kojoj se znakovi razlikuju, a nijedan od njih nije praznina. Pozicija se pritom broji u koordinatama referentne sekvence, ne poravnanja, kako bi odgovarala načinu na koji se mutacije navode u biološkoj literaturi.

5 Implementacijski detalji

5.1 Needleman–Wunsch

```

1 export function needlemanWunsch(seq1, seq2, match = 2, mismatch = -1, gap =
  -2) {
2   const m = seq1.length, n = seq2.length;
3   const dp = Array.from({ length: m + 1 }, () => Array(n + 1).fill(0));
4
5   // inicijalizacija rubova kaznama za prazninu
6   for (let i = 0; i <= m; i++) dp[i][0] = i * gap;
7   for (let j = 0; j <= n; j++) dp[0][j] = j * gap;
8
9   // popunjavanje matrice
10  for (let i = 1; i <= m; i++)
11    for (let j = 1; j <= n; j++) {
12      const s = seq1[i-1] === seq2[j-1] ? match : mismatch;
13      dp[i][j] = Math.max(
14        dp[i-1][j-1] + s,    // dijagonala
15        dp[i-1][j] + gap,    // gore
16        dp[i][j-1] + gap    // lijevo
17      );
18    }
19
20  // traceback iz donjeg desnog kuta
21  let a1 = "", a2 = "", i = m, j = n;
22  while (i > 0 || j > 0) {
23    const s = (i > 0 && j > 0)
24      ? (seq1[i-1] === seq2[j-1] ? match : mismatch) : 0;
25    if (i > 0 && j > 0 && dp[i][j] === dp[i-1][j-1] + s) {
26      a1 = seq1[i-1] + a1; a2 = seq2[j-1] + a2; i--; j--;
27    } else if (i > 0 && dp[i][j] === dp[i-1][j] + gap) {
28      a1 = seq1[i-1] + a1; a2 = "-" + a2; i--;
29    } else {
30      a1 = "-" + a1; a2 = seq2[j-1] + a2; j--;
31    }
32  }
33  return { matrix: dp, aligned1: a1, aligned2: a2, score: dp[m][n] };
34 }

```

Programski kôd 3: Jezgra algoritma Needleman–Wunsch

5.2 Smith–Waterman

```

1 export function smithWaterman(seq1, seq2, match = 2, mismatch = -1, gap = -2)
  {
2   const m = seq1.length, n = seq2.length;
3   const dp = Array.from({ length: m + 1 }, () => Array(n + 1).fill(0));
4   let maxScore = 0, maxI = 0, maxJ = 0;
5
6   for (let i = 1; i <= m; i++)
7     for (let j = 1; j <= n; j++) {
8       const s = seq1[i-1] === seq2[j-1] ? match : mismatch;
9       // razlika 1: nula kao donja granica
10      dp[i][j] = Math.max(0, dp[i-1][j-1]+s, dp[i-1][j]+gap, dp[i][j-1]+gap);
11      // razlika 2: pamcenje pozicije maksimuma
12      if (dp[i][j] > maxScore) { maxScore = dp[i][j]; maxI = i; maxJ = j; }
13    }
14
15  // traceback od maksimuma, prekid na nuli
16  let a1 = "", a2 = "", i = maxI, j = maxJ;
17  while (i > 0 && j > 0 && dp[i][j] !== 0) {

```

```

18   const s = seq1[i-1] === seq2[j-1] ? match : mismatch;
19   if (dp[i][j] === dp[i-1][j-1] + s) {
20     a1 = seq1[i-1]+a1; a2 = seq2[j-1]+a2; i--; j--;
21   } else if (dp[i][j] === dp[i-1][j] + gap) {
22     a1 = seq1[i-1]+a1; a2 = "-" + a2; i--;
23   } else {
24     a1 = "-" + a1; a2 = seq2[j-1]+a2; j--;
25   }
26 }
27 return { matrix: dp, aligned1: a1, aligned2: a2, score: maxScore };
28 }

```

Programski kôd 4: Razlike u algoritmu Smith–Waterman

5.3 Animacija popunjavanja matrice

Animacija se ne izvodi tijekom računanja — algoritam završi trenutačno, a zatim se rezultat *otkriva* postupno. Brojač `revealCount` određuje koliko je ćelija vidljivo; ćelije s indeksom većim od brojača iscertavaju se prozirno.

```

1  const total = (s1.length + 1) * (s2.length + 1);
2  const step  = Math.max(1, Math.floor(total / 50)); // ~50 koraka
3  let count = 0;
4
5  animRef.current = setInterval(() => {
6    count += step;
7    setRevealCount(count);
8    if (count >= total) {
9      clearInterval(animRef.current);
10     setRevealCount(total);
11     setAnimating(false);
12     setTimeout(() => setShowResult(true), 300);
13   }
14 }, 35); // interval od 35 ms

```

Programski kôd 5: Upravljanje animacijom

Korak se skalira prema veličini matrice, pa animacija traje približno jednako i za male i za velike ulaze.

5.4 Prilagodljiva veličina ćelije

Kako bi matrica ostala čitljiva neovisno o duljini sekvenci, veličina ćelije i font računaju se iz broja stupaca:

```

1  const cellSize = cols > 20 ? (cols > 40 ? 26 : 32) : 42;
2  const fontSize = cols > 20 ? (cols > 40 ? 9 : 10) : 12;

```

Programski kôd 6: Prilagodba dimenzija

6 Instalacija i pokretanje

6.1 Preduvjeti

- Node.js verzije 18 ili novije
- npm (dolazi uz Node.js)
- Moderni web preglednik

6.2 Postupak

```
1 # 1. Dohvati projekt
2 git clone <url-repozitorija>
3 cd sequence-alignment
4
5 # 2. Instaliraj ovisnosti
6 npm install
7
8 # 3. Pokreni razvojni poslužitelj
9 npm start
10 # aplikacija je dostupna na http://localhost:3000
```

Programski kôd 7: Pokretanje razvojnog poslužitelja

```
1 npm run build
2 # rezultat se nalazi u direktoriju build/
```

Programski kôd 8: Izrada produkcijske verzije

Literatura

1. Needleman, S. B., & Wunsch, C. D. (1970). A general method applicable to the search for similarities in the amino acid sequence of two proteins. *Journal of Molecular Biology*, 48(3), 443–453.
2. Smith, T. F., & Waterman, M. S. (1981). Identification of common molecular subsequences. *Journal of Molecular Biology*, 147(1), 195–197.
3. Compeau, P., & Pevzner, P. (2015). *Bioinformatics Algorithms: An Active Learning Approach*, Vol. 1 i 2. La Jolla, CA: Active Learning Publishers.
4. Gotoh, O. (1982). An improved algorithm for matching biological sequences. *Journal of Molecular Biology*, 162(3), 705–708.
5. Durbin, R., Eddy, S., Krogh, A., & Mitchison, G. (1998). *Biological Sequence Analysis: Probabilistic Models of Proteins and Nucleic Acids*. Cambridge University Press.
6. UniProt Consortium. UniProt: the Universal Protein Knowledgebase. Dostupno na: <https://www.uniprot.org>